

Universidad de San Carlos de Guatemala
Facultad de Ingeniería — Escuela de Ciencias y Sistemas

Project Charter

Plataforma Analítica de Mortalidad End to End

Curso: Seminario de Sistemas 2, Sección A

Catedrático: Ingeniero Marlon Orellana

Tutor académico: Estuardo Sebastián Valle Bances

Período: Escuela de Vacaciones 2026

Equipo consultor: Alberto Hernández, Fabio Hernández, Luis Morales

Versión 1.0 — 25 de junio de 2026

Resumen Ejecutivo

El presente informe documenta los resultados de la consultoría desarrollada bajo el marco de un encargo simulado del Programa de las Naciones Unidas para el Desarrollo en acompañamiento al Ministerio de Salud Pública y Asistencia Social de Guatemala. El objetivo del encargo consistió en diseñar, implementar y demostrar una plataforma de datos de punta a punta que integrara fuentes heterogéneas de mortalidad, las gobernara bajo una arquitectura por capas hacia un repositorio analítico de tipo Data Warehouse, y produjera evidencia comparativa entre el período previo a la pandemia de COVID-19, comprendido entre 2015 y 2019, y el período posterior, comprendido a partir de 2020, que sustentara recomendaciones de política pública.

La plataforma se construyó sobre tres fases acumulativas. En la primera fase se identificaron y consolidaron fuentes públicas de defunciones del Instituto Nacional de Estadística de Guatemala, de la Organización Mundial de la Salud y del Banco Mundial, además de un diccionario de variables institucional, en una zona de aterrizaje sin transformación destructiva. En la segunda fase se construyó un proceso de transformación por capas que culminó en un modelo dimensional de esquema estrella, replicado simultáneamente en un repositorio analítico en la nube y en una instancia local, con un sistema de respaldo automatizado. En la tercera fase, objeto principal de este informe, se aplicaron técnicas de aprendizaje automático sobre el repositorio consolidado para generar evidencia comparativa entre los dos períodos de interés.

Los hallazgos centrales de la fase analítica confirman que el modelo de clasificación entrenado identificó, sin indicación previa, que el capítulo de causas codificado bajo el estándar CIE-10 correspondiente a códigos especiales, donde se registra la mortalidad directa por COVID-19, constituye el predictor individual más fuerte de pertenencia al período posterior a la pandemia. Asimismo, el modelo de pronóstico de defunciones mensuales evidenció que, durante 2023 y 2024, la mortalidad observada se ubicó mayoritariamente por debajo de la tendencia histórica extrapolada, con la excepción de un valor atípico en mayo de 2024 que se señala como objeto de investigación adicional.

Introducción

La información de defunciones en Guatemala existe, pero se encuentra fragmentada entre múltiples fuentes, formatos y niveles de calidad. El registro nacional transita del Registro Nacional de las Personas hacia el Instituto Nacional de Estadística, entidad que codifica las causas de muerte bajo el estándar de la Clasificación Internacional de Enfermedades, décima revisión, en adelante CIE-10, y publica estadísticas vitales con una periodicidad anual. Esta fragmentación impide a las instituciones del sector salud responder con agilidad preguntas estratégicas sobre la evolución de los patrones de mortalidad, particularmente en el contexto del cambio estructural que representó la pandemia de COVID-19.

Bajo este encargo, el equipo consultor asumió la responsabilidad de construir una prueba de concepto de plataforma de datos de extremo a extremo que demostrara, de manera reproducible y auditable, el recorrido completo desde las fuentes originales hasta un repositorio analítico capaz de sustentar tanto consultas exploratorias como modelos predictivos. El presente documento constituye el informe final de dicha consultoría y reúne la metodología aplicada, la justificación de cada decisión técnica relevante, el tratamiento ético y de gobernanza de los datos sensibles involucrados, el análisis comparativo entre los períodos previo y posterior a la pandemia, y las recomendaciones de política derivadas de la evidencia generada.

Metodología y Justificación de las Decisiones de Ingeniería

Arquitectura por Capas

El proyecto adoptó una arquitectura de tres capas conocida en la literatura de ingeniería de datos como arquitectura medallion, compuesta por una zona de aterrizaje sin transformar, una capa de datos conformados y una capa de modelo dimensional. La zona de aterrizaje preserva la materia prima exactamente como llega de la fuente, sin ninguna transformación destructiva, con el propósito de permitir auditoría y reproceso si se detectan errores en etapas posteriores. La capa de datos conformados aplica tipado, limpieza y reglas de negocio derivadas de un análisis exploratorio previo, mientras que la capa final materializa un modelo dimensional optimizado para consulta analítica. Esta separación de responsabilidades por capa es consistente con los principios de gobernanza de datos que sostienen que ninguna transformación debe aplicarse de forma irreversible sobre la fuente original.

Modelo Dimensional: Esquema Estrella y Constelación de Hechos

El repositorio analítico se modeló siguiendo la metodología de modelado dimensional descrita por Kimball y Ross, que recomienda declarar explícitamente el grano de cada tabla de hechos antes de construir cualquier relación.

En este proyecto, el grano de la tabla de hechos principal corresponde a una defunción individual, con siete dimensiones asociadas: tiempo, geografía, causa según la jerarquía CIE-10, sexo, grupo etario, pueblo de pertenencia y lugar de ocurrencia. Adicionalmente, se incorporaron datos regionales de referencia provenientes de la Organización Mundial de la Salud y del Banco Mundial mediante una segunda tabla de hechos independiente, con grano de país, año e indicador, sin relación de llave foránea hacia la tabla de hechos de defunciones. Esta decisión responde directamente al principio metodológico mencionado: dado que ambas tablas de hechos poseen un grano incompatible entre sí, persona individual frente a agregado nacional, forzar una relación entre ellas habría violado la integridad del modelo. La coexistencia de múltiples tablas de hechos con grano distinto dentro de un mismo repositorio se documenta en la literatura como esquema de constelación de hechos (Kimball y Ross, 2013).

Orquestación de la Transformación

El proceso de transformación se organizó como un flujo de trabajo compuesto por tareas dependientes ejecutadas sobre la plataforma Databricks, en su modalidad de cómputo sin aprovisionamiento de infraestructura dedicada. Cada tarea corresponde a un cuaderno versionado de manera independiente, con dependencias explícitas entre sí de modo que la transformación de la capa de datos conformados hacia el modelo dimensional únicamente se ejecuta después de confirmarse la finalización exitosa de la etapa anterior. Las tareas correspondientes a la constelación de indicadores regionales y a la transformación principal de defunciones se diseñaron sin dependencia mutua, dado que ambas parten de fuentes independientes, lo que permite su ejecución en paralelo y reduce el tiempo total de procesamiento del flujo completo.

Cada ejecución del flujo queda registrada en una tabla de control que documenta el cuaderno ejecutado, las marcas de tiempo de inicio y finalización, el número de filas resultantes y una nota sobre la propiedad de idempotencia de la operación. Todas las transformaciones del modelo dimensional se construyeron mediante la sentencia de reemplazo completo de tabla, lo que garantiza que ejecutar el flujo en repetidas ocasiones produce un resultado idéntico, propiedad conocida como idempotencia, requisito explícito de trazabilidad para este tipo de procesos.

Selección de Técnicas de Aprendizaje Automático

El equipo consultor seleccionó la regresión logística y la regresión de cresta (*ridge regression*) como técnicas analíticas de la fase de aprendizaje automático, en cumplimiento de las técnicas explícitamente autorizadas en los términos de referencia del encargo. Ambas técnicas comparten una base matemática común, una combinación lineal de predictores, y se diferencian en la función de enlace aplicada sobre dicha combinación: la función identidad en el caso de la regresión de cresta, orientada a un problema de pronóstico de variable continua, y la función sigmoide en el caso de la regresión logística, orientada a un problema de clasificación binaria.

La regularización aplicada en ambos modelos corresponde a la penalización de norma dos, conocida como regularización de cresta, que penaliza la magnitud de los coeficientes sin forzarlos hacia cero, a diferencia de la penalización de norma uno descrita originalmente por Tibshirani para el operador de selección y reducción absoluta mínima, conocido como lasso (Tibshirani, 1996). La elección

de la penalización de norma dos sobre la de norma uno responde a que las variables predictoras categóricas, codificadas mediante la técnica de codificación de variables ficticias, generan columnas mutuamente correlacionadas dentro de cada grupo de categorías, escenario en el cual la literatura recomienda la regularización de cresta por distribuir el peso entre variables correlacionadas en lugar de eliminar arbitrariamente una de ellas.

La implementación final de ambos modelos se realizó mediante la biblioteca scikit-learn (Pedregosa et al., 2011), tras detectarse que la implementación distribuida nativa de la plataforma Databricks impone un límite de tamaño de 256 megabytes sobre cualquier objeto de modelo ajustado durante la sesión. Dado que el conjunto de datos final de entrenamiento no excede unos pocos cientos de megabytes en memoria, su procesamiento mediante una biblioteca de un solo nodo no representa una limitación de escala y permitió completar el entrenamiento sin restricciones.

Gobernanza y Ética de Datos

Cumplimiento de la Ley de Datos de la Unión Europea

El encargo estableció, en virtud de un supuesto acuerdo de cooperación internacional que vincula a centros de investigación europeos, la obligación de que la plataforma cumpliera con los principios de manejo ético de datos sensibles de salud establecidos en el Reglamento de la Unión Europea relativo a la Ley de Datos, en particular el requisito de que los datos personales sensibles se manejen de forma anonimizada o agregada antes de su explotación analítica (European Union, 2023).

Para dar cumplimiento a este requisito, el equipo consultor adoptó el marco de anonimato K, descrito originalmente por Sweeney, que establece que ningún grupo de registros que comparta el mismo conjunto de identificadores cuasi distintivos puede contener menos de K observaciones sin incurrir en riesgo de identificación individual (Sweeney, 2002). Previo a definir el umbral aplicable, se realizó una medición empírica del costo de utilidad de distintas combinaciones de identificadores cuasi distintivos sobre el conjunto completo de 919,231 registros de defunción. La combinación de municipio, año y etnia produjo una supresión de apenas el 0.64 % de los registros bajo un umbral K igual a cinco, mientras que la combinación de municipio, año y código completo de causa de muerte produjo una supresión del 29.49 % bajo el mismo umbral, resultado que se consideró inviable para preservar la utilidad analítica del conjunto de datos.

Con base en esta medición, se adoptó la decisión de generalizar la causa de muerte a su nivel de capítulo de la clasificación CIE-10, equivalente al primer carácter del código, reduciendo el espacio de 23 capítulos posibles frente a los 3,087 códigos completos distintos observados en la fuente, y de aplicar un umbral K igual a cinco sobre la combinación de municipio, año y etnia. Esta decisión ilustra el principio fundamental del marco de anonimato K, según el cual el costo de privacidad de un conjunto de datos depende directamente de la especificidad de los identificadores cuasi distintivos seleccionados, y no únicamente del tamaño de la muestra.

Complementariamente, durante el análisis exploratorio se identificó y corrigió un error de interpretación presente en la versión inicial del plan de anonimización, que atribuía erróneamente a la variable de período de edad la condición de identificador étnico. La revisión confirmó que dicha variable corresponde a la unidad de medida en la que se expresa la edad del fallecido, mientras que la

variable de pueblo de pertenencia constituye el identificador étnico real. Esta corrección se incorporó tanto al modelo dimensional final como a la definición operativa del marco de anonimización antes de su aplicación.

Análisis Comparativo de Mortalidad: Período Previo y Posterior a la Pandemia de COVID-19

Metodología Analítica

La comparación entre el período previo a la pandemia, comprendido entre 2015 y 2019, y el período posterior, comprendido entre 2020 y 2024, se sustenta metodológicamente en el enfoque de exceso de mortalidad adoptado por la Organización Mundial de la Salud, que consiste en comparar la mortalidad observada contra una línea base de mortalidad esperada construida a partir de datos del período previo a la pandemia (Msemburi et al., 2023; World Health Organization, 2021). En este proyecto, dicho enfoque se operacionalizó mediante dos técnicas complementarias. La primera, una regresión logística, clasifica cada defunción individual según su período de ocurrencia a partir de sus atributos demográficos, geográficos y de causa. La segunda, una regresión de cresta, pronostica el conteo mensual de defunciones agregado por departamento y capítulo de causa, entrenada sobre el período 2015–2022 y evaluada sobre el período 2023–2024.

Resultados del Modelo de Clasificación

El modelo de regresión logística se entrenó sobre 735,384 registros y se evaluó sobre 183,847 registros independientes. Los resultados se resumen en la tabla siguiente.

Métrica	Valor
Registros de entrenamiento	735,384
Registros de prueba	183,847
Área bajo la curva ROC	0.6171
Exactitud	0.5867
Puntuación F1	0.6656

Nota. Elaboración propia a partir del modelo de regresión logística entrenado sobre el repositorio analítico del proyecto.

Un valor de área bajo la curva superior a 0.50 indica que el modelo posee una capacidad de discriminación real entre ambos períodos, aunque de magnitud moderada, resultado esperable dado que la mayoría de las causas de muerte no varían radicalmente con la ocurrencia de una pandemia.

Hallazgo Principal: Identificación de la Firma de la Pandemia

El coeficiente de mayor magnitud absoluta de todo el modelo correspondió al capítulo de la clasificación CIE-10 identificado con la letra U, capítulo reservado a códigos especiales que incluye la codificación específica de la mortalidad directa por COVID-19, con un valor de 7.19. Este resultado supera ampliamente al segundo coeficiente en magnitud, correspondiente a la variable de pueblo de pertenencia Xinka, con un valor de 1.18. La magnitud relativa de este hallazgo constituye una validación de coherencia del modelo: sin que se le proporcionara ninguna indicación explícita sobre la existencia de la pandemia, el modelo identificó por sí mismo que dicho capítulo de causa constituye el predictor individual más fuerte de pertenencia al período posterior a la pandemia.

Hallazgo Secundario: Comportamiento de las Causas Respiratorias Generales

El capítulo de enfermedades del sistema respiratorio, identificado con la letra J, presentó un coeficiente de $-0,63$, asociándolo en mayor medida con el período previo a la pandemia. Este resultado, contraintuitivo a primera vista, es consistente con un fenómeno documentado a nivel internacional según el cual las medidas de mitigación adoptadas durante la pandemia, entre ellas el uso de mascarilla y la restricción de movilidad, redujeron significativamente la transmisión de otras enfermedades respiratorias no asociadas a COVID-19. Dado que la mortalidad directa por COVID-19 se contabiliza específicamente bajo el capítulo U y no bajo el capítulo J, el descenso relativo observado en este último sugiere que la reducción de la transmisión de enfermedades respiratorias distintas a COVID-19 tuvo un peso mayor que cualquier incremento marginal dentro de esta categoría general durante el período evaluado.

Resultados del Modelo de Pronóstico

El modelo de regresión de cresta se entrenó sobre el período 2015–2022 y se evaluó sobre el período 2023–2024, alcanzando un coeficiente de determinación de 0.5227, una raíz del error cuadrático medio de 26.83 defunciones y un error absoluto medio de 13.47 defunciones, sobre un conjunto agregado a nivel de departamento, capítulo de causa y mes.

La comparación entre la mortalidad observada y la mortalidad esperada reveló que la mayoría de los meses evaluados en 2023 (nueve de doce) presentaron

mortalidad observada por debajo de lo que el modelo habría anticipado. Este resultado es consistente con un proceso de normalización posterior a la pandemia, en el cual la mortalidad general no exhibe un arrastre sostenido una vez superada la fase aguda del impacto directo e indirecto de la enfermedad. Se identificó un valor atípico relevante en mayo de 2024, mes en el que la mortalidad observada superó en 1,488 defunciones lo esperado según el modelo, la desviación positiva más alta de todo el período de evaluación, que se recomienda investigar de manera específica por causa y departamento en estudios posteriores.

Recomendaciones de Política Pública

Fortalecimiento del Registro de Asistencia Médica

El modelo de clasificación identificó que las defunciones sin registro de nivel de asistencia médica recibida se asociaron en mayor medida con el período posterior a la pandemia, con un coeficiente de 1.00. Este hallazgo sugiere un vacío de información que limita la capacidad de monitoreo de la calidad de atención en salud durante períodos de alta demanda del sistema. Se recomienda que el Ministerio de Salud Pública y Asistencia Social emita una directiva orientada a reforzar la completitud de este campo en el certificado de defunción.

Investigación del Exceso de Mortalidad de Mayo de 2024

Dado que el mes de mayo de 2024 constituye el valor atípico de mayor magnitud detectado en el período de evaluación del modelo de pronóstico, se recomienda una investigación específica desagregada por causa de muerte y departamento para determinar si dicha desviación responde a un evento puntual o a un cambio estructural no capturado por el modelo agregado.

Vigilancia de Enfermedades Respiratorias no Asociadas a COVID-19

El hallazgo de que el capítulo de enfermedades respiratorias generales se asoció en mayor medida con el período previo a la pandemia sugiere un efecto protector colateral de las medidas de mitigación. Conforme dichas medidas se relajan de manera permanente, se recomienda mantener vigilancia epidemiológica sobre si la mortalidad por causas respiratorias no asociadas a COVID-19 retorna a sus niveles previos a la pandemia.

Adopción del Nivel de Capítulo CIE-10 como Estándar de Reporte

Tanto el hallazgo de calidad de datos identificado durante la fase exploratoria del proyecto, que reveló que el 13.55 % de las causas de muerte registradas corresponden a códigos clasificados como síntomas y signos mal definidos, como los resultados del presente análisis, confirman que el nivel de capítulo de la clasificación CIE-10 constituye el nivel de agregación que produce señales estadísticamente robustas e interpretables para fines de reporte poblacional, en contraste con el código completo, cuya alta dispersión limita su utilidad para el análisis agregado.

Limitaciones del Estudio

El área bajo la curva de 0.62 obtenida por el modelo de clasificación indica un poder discriminativo moderado y no fuerte, lo que refleja que los atributos demográficos disponibles no determinan por sí solos el período de ocurrencia de una defunción, condición esperable que no invalida los hallazgos individuales sobre los coeficientes del modelo. El modelo de pronóstico, por su parte, no incorpora variables exógenas como condiciones climáticas o eventos epidemiológicos específicos que podrían explicar con mayor precisión los meses de mayor desviación respecto al patrón histórico. Finalmente, la proporción de causas de muerte clasificadas como mal definidas introduce un nivel de ruido inherente en cualquier análisis desagregado por causa específica, limitación que afecta a la fuente original de datos y no a la metodología analítica aplicada en este proyecto.

Conclusiones

La consultoría documentada en este informe demostró la viabilidad técnica de construir, de manera reproducible y auditable, una plataforma de datos de extremo a extremo capaz de integrar fuentes heterogéneas de mortalidad, gobernarlas bajo principios éticos de anonimización conformes con la normativa europea de protección de datos, y producir evidencia analítica robusta sobre el impacto estructural de la pandemia de COVID-19 en los patrones de mortalidad de Guatemala. El hallazgo de que el modelo de aprendizaje automático identificó de manera autónoma la mortalidad por COVID-19 como el predictor más fuerte de pertenencia al período posterior a la pandemia constituye una validación sustantiva de la coherencia del repositorio analítico construido a lo largo de las tres fases del proyecto, y respalda la confiabilidad de las recomendaciones de política pública derivadas del análisis.

Referencias

- European Union. (2023). *Regulation (EU) 2023/2854 of the European Parliament and of the Council on harmonised rules on fair access to and use of data (Data Act)*. Official Journal of the European Union.
- Kimball, R., & Ross, M. (2013). *The data warehouse toolkit: The definitive guide to dimensional modeling* (3rd ed.). Wiley.
- Msemburi, W., Karlinsky, A., Knutson, V., Aleshin-Guendel, S., Chatterji, S., & Wakefield, J. (2023). The WHO estimates of excess mortality associated with the COVID-19 pandemic. *Nature*, 613(7942), 130–137.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Sweeney, L. (2002). k-anonymity: A model for protecting privacy. *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems*, 10(5), 557–570.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.
- World Health Organization. (2021). *WHO COVID-19 excess mortality estimation methodology*. World Health Organization.